

Student Habits vs Academic Performance

Popis problematiky

V této práci se budeme věnovat analýze dat, která propojují studijní výsledky studentů s jejich každodenními návyky. Hlavním cílem je zjistit, jak různé aspekty životního stylu ovlivňují úspěch u zkoušek.

Soubor dat obsahuje záznamy o 1000 studentech a zahrnuje 15 různých charakteristik: od toho, jak se učí (počet hodin studia, výsledky testů), až po to, jak žijí (spánek, strava, aktivita na sociálních sítích a psychická pohoda). Tato data velmi věrně odrážejí situace ze skutečného života. Díky tomu je možné přesně vypočítat, co má na známky největší vliv, a také rozdělit studenty do skupin podle jejich podobného životního stylu.

Zdroj dat

Data pro tuto analýzu byla čerpána z platformy Kaggle, ze sady s názvem „Student Habits vs Academic Performance“. Jedná se o syntetický soubor dat, který byl vytvořen pro účely vzdělávání, aby simuloval reálné vzorce chování studentů a jejich vliv na studijní výsledky.

Odkaz na původní zdroj: <https://www.kaggle.com/datasets/jayaantanaath/student-habits-vs-academic-performance>

Popis proměnných

Náš soubor obsahuje celkem 15 charakteristik:

student_id – unikátní identifikátor studenta, charakteristická hodnota (text).

study_hours_per_day – průměrný počet hodin studia denně, číselná hodnota.

part_time_job – informace o brigádě, charakteristická hodnota (Yes, No).

attendance_percentage – procento docházky na výuku, číselná hodnota.

sleep_hours – průměrný počet hodin spánku za noc, číselná hodnota.

diet_quality – kvalita stravování, charakteristická hodnota (Poor, Fair, Good).

exercise_frequency – počet tréninků nebo fyzické aktivity týdně, číselná hodnota.

mental_health_rating – hodnocení psychické pohody, číselná hodnota (1 = velmi špatný stav, 10 = velmi dobrý stav)


exam_score – výsledné hodnocení u zkoušky, číselná hodnota.

social_media_h – čas strávený na sociálních sítích denně, číselná hodnota.


Úkol №2

study hours per day

Průměr: 3.55
Medián: 3.50
Min a max : 0.00 a 8.30
Směrodatná odchylka : 1.46889
Rozptyl : 2.157638
Mezikvartilové rozpětí (IQR): 1.90




Hodiny studia




Medián (3,50) je téměř stejný jako průměr (3,55), což ukazuje na symetrii dat. Je to dobře vidět i na histogramu, kde je graf zleva i zprava téměř vyvážený. Nízká směrodatná odchylka (1,47) a hodnota IQR (1,90) potvrzují, že výsledky většiny studentů jsou soustředěny blízko středu. Z toho vyplývá, že variabilita není velká, i když je v souboru několik lidí, kteří studují kolem 8 hodin, což mírně prodlužuje rozsah dat

attendance percentage

Průměr: 84.13
Medián: 84.40
Min a max : 56 a 100
Směrodatná odchylka : 9.399246
Rozptyl : 88.34583
Mezikvartilové rozpětí (IQR): 13.025




attendance




Průměrná docházka je 84,13 % a medián 84,40 %, jsou téměř stejné ale histogram ukazuje na mírnou levostrannou asymetrii. Většina studentů má vysokou docházku nad 80 %, ale skupina studentů s velmi nízkými hodnotami mírně táhne průměr dolů. Směrodatná odchylka 9,40 se může zdát vysoká, ale v přepočtu na reálnou docházku jde v průměru pouze o 1 přednášku, takže skutečná variabilita dat je malá. Většina studentů se chová velmi podobně a výrazněji vybočuje jen několik odlehlých hodnot pod 60 %, které vidíme na boxplotu

sleep hours

Průměr: 6.47
Medián: 6.5
Min a max : 3.20 a 10
Směrodatná odchylka : 1.226377
Rozptyl : 1.504
Mezikvartilové rozpětí (IQR): 1.7




sleep_hours



Průměrná délka spanku je 6,47 hodiny, což se téměř shoduje s mediánem (6,5 hodiny). Histogram i boxplot ukazují na velmi symetrické rozdělení dat bez výrazné asymetrie. Směrodatná odchylka 1,23 a nízké mezikvartilové rozpětí 1,7 potvrzují, že většina studentů spí podobně dlouho a variabilita je malá. V datech se vyskytuje pouze jedna odlehlá hodnota 10 hodin, ale celkově jsou výsledky velmi stabilní

social media h


Průměr: 4.325
Medián: 4.4
Min a max : 0.2 a 10.1
Směrodatná odchylka : 1.599808
Rozptyl : 2.559384
Mezikvartilové rozpětí (IQR): 2.1



Data vykazují mírnou pravostrannou asymetrii s delším koncem u vyšších hodnot, což potvrzuje medián 4,4. Směrodatná odchylka 1,6 a IQR 2,1 ukazují, že většina studentů tráví na sítích 3 až 6 hodin denně. Boxplot identifikuje několik odlehlých hodnot nad 8 hodinami, ale celkově jsou data dobře koncentrována kolem střední hodnoty

exam score


Průměr: 69.6
Medián: 70.5
Min a max : 18.40 a 100
Směrodatná odchylka : 16.88856
Rozptyl : 285.2236
Mezikvartilové rozpětí (IQR): 22.85



Průměr 69,6 je nižší než medián 70,5, což značí mírnou levostrannou asymetrii. Histogram potvrzuje, že většina studentů má dobré výsledky, ale protažení rozdělení směrem k nižším hodnotám tvoří slabší žáci.. Vysoká směrodatná odchylka 16,89 ukazuje na velkou rozmanitost ve znalostech. Boxplot navíc identifikuje několik odlehlých hodnot u studentů, kteří v testu výrazně propadli

exercise frequency


Průměr: 3.042
Medián: 3
Min a max : 0 a 6
Směrodatná odchylka : 2.025423
Rozptyl : 4.102338
Mezikvartilové rozpětí (IQR): 4



Průměr 3,04 a medián 3 jsou téměř shodné, což potvrzuje vysokou symetrii dat. Sloupcový graf ukazuje, že počty studentů ve všech kategoriích jsou vyrovnané a žádná skupina nedominuje. Variabilita je přirozená a v souboru se nevyskytují žádné odlehlé hodnoty



mental health rating

Průměr: 5.438
Medián: 5
Min a max : 1 a 10
Směrodatná odchylka : 2.847501
Rozptyl : 8.108264
Mezikvartilové rozpětí (IQR): 5



Průměr 5,44 i medián 5 potvrzují rovnoměrné rozložení odpovědí v celém rozsahu škály 1 až 10. Sloupcový graf ukazuje, že četnosti jednotlivých hodnocení jsou si velmi blízké a žádná kategorie výrazně nedominoje. Směrodatná odchylka 2,85 a vysoké IQR 5 značí značnou subjektivní variabilitu v odpovědích studentů.

Kategoriální proměnné: c



Většina studentů v souboru má dobrou nebo průměrnou kvalitu stravování a zároveň nemá vedlejší pracovní poměr

Hypoteza

Pro podrobnou analýzu jsme zvolili proměnnou **exam_score**. Na základě našich dat jsme stanovili intervalový odhad mediánu, který se s 95% spolehlivostí pohybuje v rozmezí 68,70 až 70,90 bodu.

Na základě těchto hodnot jsme stanovili hypotézu, že typický výsledek studenta 70 bodů.

Definujeme hypotézy:

$$H_0: x_{05} = 70$$

$$H_a: x_{05} \neq 70$$

Na začátku analýzy musíme provést Shapiro-Wilkův test normality, abychom zjistili, zda je naše rozdělení normální. Tento test ukázal výsledek p-hodnota = 0,00000008, což je výrazně méně než hladina významnosti $\alpha = 0,05$. Z toho vyvozujeme závěr, že naše data nemají normální rozdělení. Proto musíme pro další analýzu a ověření hypotézy použít neparametrický test.


Vzhledem k tomu, že data vykazují určitou asymetrii, použili jsme jednovýběrový znaménkový test (One-sample Sign-Test). Naše nulová hypotéza předpokládala, že typický výsledek studenta (medián) je roven 70 bodům.

Výsledky testu ukázaly, že 95% interval spolehlivosti (confidence interval) pro medián se pohybuje v rozmezí 68,75 až 71,10. Získaná p-hodnota je 0,5269. Protože je tato hodnota výrazně vyšší než 0,05, nemůžeme zamítnout nulovou hypotézu.


Na základě provedené analýzy jsme statisticky potvrdili, že typický výsledek studenta se významně neliší od 70 bodů. Přestože rozdělení známek není ideálně normální, výsledky svědčí o tom, že průměrná úspěšnost (medián) se stabilně drží na úrovni naší stanovené hypotézy.

Úkol №3

part time job



1) Pro analýzu byla zvolena proměnná **part_time_job**. Testovaná hypotéza předpokládala 80% podíl studentů s brigádou ($H_0: p = 0.8$). Na základě binomiálního testu (785 úspěchů z 1000) je p-hodnota = 0.2357. Protože $p > 0.05$, nulovou hypotézu nezamítáme. Rozdíl mezi výběrovým podílem (78.5 %) a hypotézou není statisticky významný, což potvrzuje i interval spolehlivosti (0.758; 0.810), který hodnotu 0.8 obsahuje.



2) Pro podrobnou analýzu jsme zvolili faktorovou proměnnou **diet_tab**. Na základě našeho teoretického předpokladu jsme stanovili hypotézu, že rozdělení do kategorií (Fair, Good, Poor) je dáno pravděpodobnostmi 45%, 35 % a 20 %.

Definujeme hypotézy:

H₀: Rozdělení odpovídá pravděpodobnostem:

$$p(\text{Fair}) = 0.45$$


$$p(\text{Good}) = 0.35$$

$$p(\text{Poor}) = 0.20$$

H_a: Rozdělení neodpovídá těmto pravděpodobnostem

Na začátku analýzy jsme provedli grafické srovnání pozorovaných a očekávaných četností pomocí sloupcového grafu. Vizuální kontrola ukázala, že se skutečné (pozorované) četnosti velmi těsně blíží těm očekávaným. Vzhledem k tomu, že pracujeme s kategoriální proměnnou a zjišťujeme shodu s teoretickým rozdělením, musíme pro statistické ověření hypotézy použít Pearsonův test dobré shody (Chi-squared test). Tento test ukázal výsledek $p\text{-hodnota} = 0,1541$, což je více než hladina významnosti $\alpha = 0,05$. Z toho vyvozujeme závěr, že nemáme dostatek důkazů pro zamítnutí nulové hypotézy. Naše data tedy neodporují předpokládanému rozdělení pravděpodobností.


3) Pro podrobnou analýzu jsme zvolili spojitou proměnnou **sleep_hours**. Na základě našich dat jsme testovali předpoklad, zda rozdělení této proměnné odpovídá normálnímu rozdělení.



Na začátku analýzy jsme provedli vizuální kontrolu dat. Histogram má víceméně symetrický zvonovitý tvar a body na Q-Q plotu leží velmi blízko diagonální přímky. Obě grafické reprezentace silně naznačují, že rozdělení je normální.

Následně musíme provést Shapiro-Wilkův test normality. Tento test ukázal výsledek p-hodnota = 0,08878, což je více než hladina významnosti $\alpha = 0,05$. Z toho vyvozujeme závěr, že naše data podle tohoto testu mají normální rozdělení.

Pro další ověření jsme provedli také Pearsonův test dobré shody při neznámých parametrech. K tomu jsme využili jak rychlý výpočet pomocí funkce PearsonTest, tak i manuální postupný výpočet. Výsledky obou těchto přístupů se exaktně shodovaly. Test ukázal testovou statistiku 81,6 a p-hodnotu = 0,000000674, což je méně než $\alpha = 0,05$. Podle tohoto testu bychom měli normalitu zamítnout.



Jelikož grafy a přesnější Shapiro-Wilkův test normalitu potvrzují, považujeme rozdělení za normální. Zamítnutí u Pearsonova testu je způsobeno pouze jedinou lokální anomálií v datech

Úkol №4

1) Pro analýzu jsme zvolili dvě proměnné: čas na sociálních sítích (social_media_h) a hodnocení duševního zdraví (mental_health_rating). K ověření tohoto vztahu použijeme Pearsonův test nezávislosti χ^2 v kontingenční tabulce.


Definice hypotéz:

- **H₀:** Duševní zdraví nezávisí na čase stráveném na sociálních sítích (proměnné jsou nezávislé).
- **H_a:** Mezi těmito proměnnými existuje statisticky významná závislost (proměnné jsou závislé).

Aby test proběhl bez chyb, rozdělili jsme čas do 4 skupin (0-2h, 2-4h, 4-6h, > 6h) a hodnocení zdraví jsme sloučili po dvou. Naším cílem je ověřit, zda duševní zdraví závisí na tom, kolik času člověk tráví na internetu.

	0-2h	2-4h	4-6h	> 6h	Sum		0-2h	2-4h	4-6h	> 6h
1-2	12	76	82	26	196	1-2	0.13	0.22	0.19	0.19
3-4	24	70	94	27	215	3-4	0.27	0.20	0.22	0.20
5-6	16	70	91	30	207	5-6	0.18	0.20	0.21	0.22
7-8	23	66	81	26	196	7-8	0.26	0.19	0.19	0.19
9-10	15	64	81	26	186	9-10	0.17	0.18	0.19	0.19
Sum	90	346	429	135	1000					

Nejprve jsme sestavili běžnou tabulku s počty osob (absolutní četnosti). Vzhledem k tomu, že počty studentů v jednotlivých skupinách se velmi liší (například pouze 90 lidí tráví na sítích 0-2 hodiny, zatímco celých 429 lidí 4-6 hodin), nelze je přímo porovnávat. Proto jsme pro každý sloupec vypočítali procenta (relativní četnosti).



Z grafu „Relativní struktura“ je jasné patrné, že bez ohledu na to, kolik hodin studenti tráví na sociálních sítích, zůstává podíl dobrých a špatných hodnocení zdraví přibližně stejný.


Pro statistické ověření jsme použili Pearsonův χ^2 test. Ujistili jsme se, že všechny očekávané četnosti jsou větší než 5 (nejmenší se rovná 16,74), proto jsou výsledky testu zcela spolehlivé. Test ukázal následující výsledky: $\chi^2 = 7,0466$ a $p\text{-hodnota} = 0,8545$. Jelikož je $p\text{-hodnota}$ (0,8545) mnohem větší než standardní hladina významnosti $\alpha = 0,05$, můžeme vyvodit závěr, že podle našich dat neexistuje žádný statisticky významný vztah mezi časem stráveným na sociálních sítích a hodnocením duševního zdraví.

2) Pro analýzu spojitých proměnných jsme zvolili dobu studia **study_hours_per_day** a výsledek zkoušky **exam_score**. Cílem je zjistit, zda a jak silně spolu tyto dvě veličiny souvisí.

Pro posouzení vztahu mezi dobou studia a výsledkem zkoušky použijeme test významnosti Spearmanova koeficientu korelace, a to z důvodu absence normálního rozdělení u jedné z proměnných.



Definice hypotéz:

- **H₀**: Korelace mezi hodinami studia a výsledkem zkoušky je rovna nule (neexistuje monotónní vztah).
- **H_a**: Korelace mezi proměnnými je různá od nuly (existuje statisticky významný monotónní vztah).



Na začátku jsme vztah vizualizovali pomocí bodového grafu. Z grafu je na první pohled patrná silná pozitivní závislost. Studenti, kteří se učí více hodin denně, dosahují lepších výsledků u zkoušky.

Abychom mohli vybrat správný korelační koeficient pro statistické ověření, museli jsme nejprve otestovat normalitu obou proměnných pomocí histogramů a Shapiro-Wilkova testu.



Histogram doby studia se jeví poměrně symetricky, což také potvrzuje Shapiro-Wilkův test, který ukázal, že p-hodnota = 0,1065, což je více než 0,05, a proto je rozdělení normální.

Histogram výsledků zkoušek je však viditelně zešikmený k vyšším hodnotám a test ukázal hodnotu nižší než 0,05, takže toto rozdělení není normální (p-value = 8.675e-08).

Pro otestování závislosti jsme využili Spearmanův korelační koeficient. Test ukázal, že p-hodnota < 2,2e-16, což je výrazně méně než hladina významnosti $\alpha = 0,05$. Takže vidíme, že mezi našimi proměnnými existuje statisticky významný monotónní vztah. Hodnota korelačního koeficientu ρ je 0,812, což ukazuje na velmi silnou pozitivní korelaci. Platí tedy, že čím více hodin denně student věnuje studiu, tím lepších výsledků u zkoušky dosahuje.